Clasificación de la predisposición genética al alcoholismo por medio del análisis de señales EEG usando técnicas de ML

Diego A. Suárez Mejía*
*Universidad Pontificia Bolivariana - Seccional Bucaramanga
Campus Universitario Km 7 vía Piedecuesta - Floridablanca, Santander
diego.suarez.2018@upb.edu.co

***Abstract*—Alcoholism is a serious public health problem that affects a large number of people, causing millions of premature deaths. The interpretation of EEG signals can provide a diagnosis through the use of machine learning techniques. In this research a statistical analysis of EEG signals over time is performed from which characteristics such as maximum and minimum values, the range (the difference between these two) and the standard deviation are extracted. Finally, a classification is performed using support vector machines and neural networks, the simulation showed a high percentage of accuracy in classifying alcoholic and non-alcoholic persons taking into account statistical characteristics.**

***Index Terms*—Alcoholism, EEG, Machine Learning, Neural Networks, Support Vector Machines, Time Domain.**

I. Introducción

El cerebro es un sistema altamente complejo. Interpretar la información que proveen las señales generadas por la interacción de miles de millones de neuronas ha sido uno de los objetivos a cumplir con este enigmático sistema. El electroencefalograma (EEG) es un método de medición que registra el valor de potenciales donde se refleja la actividad eléctrica del cerebro, es generalmente utilizado por científicos y físicos para estudiar las funciones cerebrales y así poder diagnosticar trastornos neurológicos [1].

El alcoholismo es un grave problema de salud pública. The Institute for Health Metrics and Evaluation (HME), un centro independiente de investigación sobre la salud mundial, en uno de sus estudios estadísticos relaciona el número de muertes atribuidas a los factores de riesgo, de los cuales el consumo de alcohol se encuentra dentro de los 10 primeros factores de riesgo, y de sólo este se piensa que se provocan alrededor de 2.8 millones de muertes prematuras al año [2].

El uso de señales de EEG han demostrado ser lo suficientemente útiles para proporcionar medidas de algunos efectos agudos y crónicos del alcohol en el cerebro [3]. El uso de técnicas aprendizaje automático está ampliamente descrito en la literatura y en la práctica médica en relación con la clasificación de señales de EEG. Esto ofrece una forma eficiente de ayudar a los profesionales en los diagnósticos automatizados, proporcionando altas tasas de precisión [4]. Además, las técnicas de adquisición de EEG son cada vez más eficientes y rápidas [5], y las estrategias de procesamiento y clasificación de las señales de EEG son cada vez más precisas y robustas. Estos avances benefician significativamente tanto a las aplicaciones médicas como a las industriales, ya que a medida de que el diagnostico se haga más fiable, los costos se hacen menores. Por lo tanto, la evolución de estas técnicas incrementa la viabilidad de la aplicación de las señales de EEG para el diagnóstico del alcoholismo mediante técnicas de aprendizaje automático [6].

Este artículo se ha organizado de la siguiente manera. En la sección 2 se introduce el material y los métodos utilizados que se llevaron para la elaboración de este proyecto. En la sección 3, se describe la extracción y selección de la característica, en la sección 4 se presentan los métodos de clasificación utilizados, para finalmente, en la sección 5 presentar los resultados obtenidos.

II. Material y métodos

Los datos de EEG utilizados pertenecen al EEG Database de la State University of New York Center. Esta base de datos presenta un amplio estudio donde se examina la correlación entre señales EEG y la predisposición genética al alcoholismo.

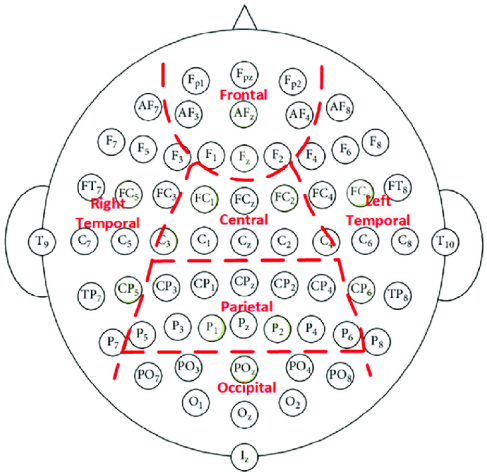


Fig. 1: Representación gráfica de la nomenclatura estándar de la posición de los electrodos [7].

Se realizaron mediciones en 64 electrodos ubicados en el cuero cabelludo del sujeto de los cuales se obtuvieron 256 muestras en 1 segundo. Figura 1. Las pruebas fueron realizadas a dos grupos de personas: Alcoholicos y de control (no alcoholicos). Cada persona fue expuesta a uno o dos estimulos los cuales corresponden a imagenes de objetos escogidos del set de imagenes de Snoodgrass y Vanderwart de 1980.

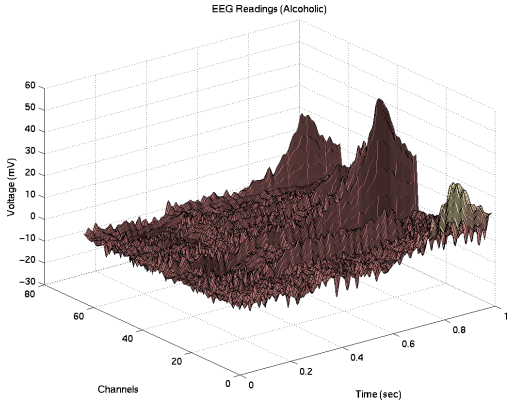


Fig. 2: Lecturas de EEG (Alcohólicos).

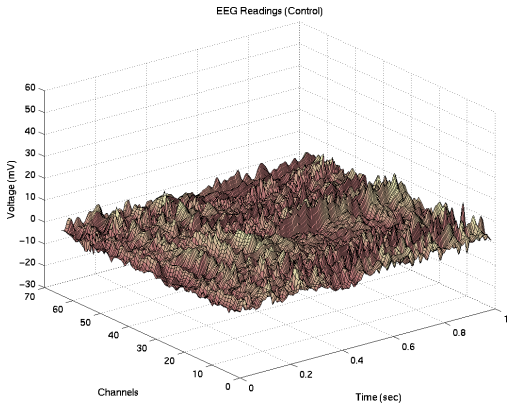


Fig. 3: Lecturas de EEG (Control).

En las figuras 2 y 3 se indican el voltaje, el tiempo y el canal para las lecturas de EEG para sujetos alcohólicos y de control [8].

Para esta investigación se utilizó la versión 'The Large Dataset' del EEG Database, el cual proporciona la información de 20 sujetos de los cuales 10 son alcohólicos, 10 son de control y para cada uno se tienen 60 EEG, se consideró el 80% de los datos para el entrenamiento y el 20% restante para la prueba.

Se tuvieron en cuenta parámetros estadísticos en el dominio del tiempo tales como: media, mediana, curtosis, asimetría, valores máximos, rango, valores mínimos y desviación estándar.

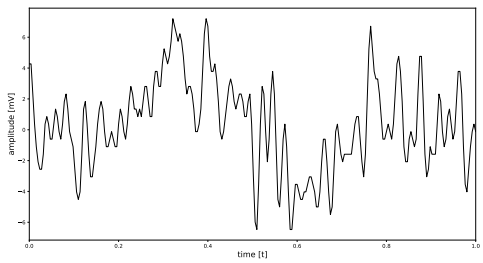


Fig. 4: Ejemplo de señal EEG utilizada en esta investigación.

En la figura 4 se ilustra un típico ejemplo de una señal EEG que corresponde a la información del LargeDataset del EEG Dataset. Este ejemplo corresponde a la medición del canal 1 de una persona con alcoholismo.

III. Extracción y selección de características

A. *Parámetros Estadísticos*

Al observar las figuras 2 y 3 que provee la base de datos es evidente encontrar una diferencia entre las personas alcohólicas y las no alcohólicas. Principalmente se aprecia que la amplitud en los primeros canales, los del medio y los últimos son muchos más altos en las personas alcohólicas. Por lo que se vio pertinente realizar un análisis estadístico por canal, se evaluaron modelos teniendo en cuenta todos los parámetros estadísticos mencionados anteriormente, cada uno representaría una matriz de característica diferente. Inicialmente se hizo la hipótesis de que los valores máximos, mínimos, el rango y la desviación estándar podrían obtener un buen desempeño de acuerdo a lo observado en las gráficas. Al evaluar los modelos coincidió la hipótesis con que los parámetros estadísticos que podrían ser determinantes para la clasificación, se obtuvo como resultado una matriz característica por cada parámetro estadístico seleccionado, cuatro matrices de 1600 x 64 (tomando todas las características, 64 canales). Posterior a ello se realizó para cada una el escalamiento estandarizado de los datos.

B. *Análisis del Componente Principal (PCA)*

Si bien, al interpretar las figuras 2 y 3 fue posible tener una idea de que parámetros estadísticos serían pertinentes para la clasificación, también es posible creer que no todos los canales aportan información útil a la hora de implementar el algoritmo de clasificación, por lo que se vio pertinente realizar un análisis del componente principal (PCA). De cada una de las matrices características

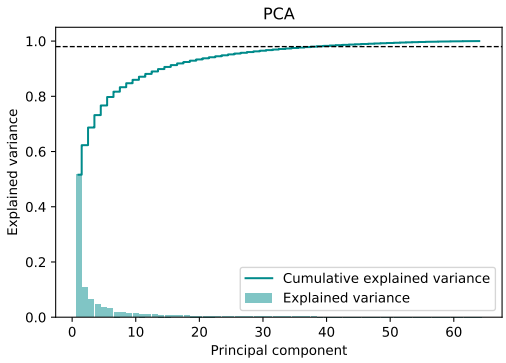


Fig. 5: Análisis del Componente Principal

En la figura 5 se presenta el análisis del componente principal, en el eje horizontal se encuentra el número de características (64 canales) y en el eje vertical la varianza explicada. La línea puntuada negra corresponde al 0.98 de la varianza explicada la cual se intercepta con la recta de la varianza

explicada acumulada en aproximadamente 35 características. Por lo anterior, se decidió implementar una reducción de la dimensionalidad con la herramienta PCA, con el objetivo de reducir el costo computacional y el tiempo de ejecución a la hora de identificar el mejor modelo de clasificación.

IV. Enfoque de la clasificación

En esta parte da una breve descripción de los parámetros estadísticos utilizados para extraer las cuatro matrices características, los clasificadores que se utilizaron para discriminar estas características y las métricas que se usaron para evaluar el desempeño.

A. Características Estadísticas

1) Valor Máximo (Máx): Corresponde al máximo valor dentro de un arreglo de elementos

2) Valor Mínimo (Mín): Corresponde el mínimo valor dentro de un arreglo de elementos

3) Rango (Range): El rango corresponde a la diferencia entre el valor máximo y el valor mínimo.

$$X_{max} - X_{min} \tag{1}$$

4) Desviación Estandar (Std): La desviación estandar corresponde a la raíz cuadrada de la varianza, se trata de la variabilidad que existe entre los datos.

$$s^2 = \sum_{n=1}^{i} \frac{(x_i - \bar{x})^2}{n-1} \tag{2}$$

$$s = \sqrt{s^2} \tag{3}$$

B. Técnicas de Clasificación

1) Clasificador SVM no linear: El clasificador SVM lineal puede extenderse fácilmente a un clasificador no lineal utilizando un operador no lineal $\Phi(.)$ para mapear el patrón de entrada x en un espacio de mayor dimensión H. El clasificador SVM no lineal obtenido a partir de este procedimiento se define como:

$$f(x) = w^T \Phi(\mathrm{x}) + b \tag{4}$$

Que es lineal en términos de los datos transformados $\Phi(.)$, pero no lineal en términos de los datos originales $\mathrm{x} \in \mathrm{R^n}$. Tras transformación no lineal, los parámetros de la función de decisión $\mathrm{f}(\mathrm{x})$ se determinan mediante la siguiente minimización:

$$\min J(w, \xi) = \frac{1}{2} w2 + C \sum_{i=1}^{i} \xi_i \tag{5}$$

Sujeto a:

$$y_i \left(w^T \Phi(x_i) + b \right) \geqslant 1 - \xi_i, \xi_i \geqslant 0; \tag{6}$$

El mapeo $\Phi(.)$entra en el problema sólo implícitamente a través de la función kernel K(.,.) por lo tanto, sólo es necesario definir K(.,.) que define implícitamente $\Phi(.)$. En esta investigación se considera la RBF gaussiana como la función de núcleo, que muestra el mejor rendimiento de mapeo para nuestro espacio de características y se define como sigue:

$$k(x, y) = exp \frac{||x - y||^2}{2\sigma^2} \tag{7}$$

Donde $\sigma > 0$ es una constante que define la anchura del kernel [9]

2) Redes Neuronales: La red neuronal artificial (ANN) es un método muy potente y eficaz para discriminar entre los no alcohólicos y los alcohólicos. Puede utilizarse como herramienta de diagnóstico automático. El enfoque de la ANN permite la clasificación de datos extremadamente ruidosos, como la señal de EEG, mediante un proceso de aprendizaje que permite a la red generalizar los ejemplos de un conjunto de entrenamiento. En esta investigación, la red utilizada para la clasificación de los patrones de EEG es un perceptrón multicapa. Se considera esta red perceptrón multicapa entre 15 y 18 capas ocultas. Para el paso de entrenamiento y el paso de prueba se utiliza el conjunto de datos de entrenamiento y el conjunto de datos de prueba, respectivamente. Se utilizan dos métodos de aprendizaje para este proyecto para las cuatro características utilizadas, lbfgs (es un optimizador de la familia de los métodos quasi-Newton.) y adam (se refiere a un optimizador basado en el gradiente estocástico propuesto por Kingma, Diederik y Jimmy Ba). La función de activación que mejor se ajustó a todas las características es relu (la función lineal unitaria rectificada)

Para todos los algoritmos de clasificación se utilizó la herramienta GridSearchCV suministrándole varios rangos de parámetros, obteniendo como resultado los parametros del mejor clasificador de acuerdo a la mejor exactitud, evaluada con una validación cruzada de 5 iteraciones.

C. Métricas de evaluación

1) Validación cruzada: La validación cruzada es un método estadístico para evaluar el rendimiento de la generalización que es más estable y exhaustivo que el uso de una división en un conjunto de entrenamiento y otro de prueba. En la validación cruzada, los datos se dividen repetidamente y se entrenan múltiples modelos. La versión más utilizada de la validación cruzada es la validación cruzada de k veces, donde k es un número especificado por el usuario, normalmente 5 o 10.

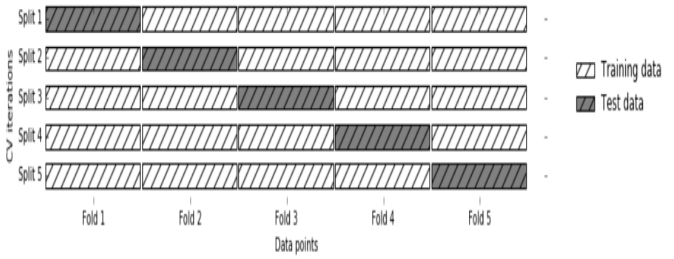


Fig. 6: División de datos en la validación k = 5

2) Exactitud (Accuracy): Es la relación entre las muestras correctamente clasificadas con respecto al número total de muestras

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \tag{8}$$

3) F1-macro: representa la media armónica de precisión y sensibilidad. Valores cercanos a 1 indican que el rendimiento de clasificación es alto.

$$F1 - score = \frac{2TP}{2TP + FP + FN} \tag{9}$$

4) Sensibilidad (Recall): representa la relación entre las muestras positivas correctamente clasificadas con respecto al número total de muestras positivas [10].

$$Recall = \frac{TP}{TP + FN} \tag{10}$$

V. Resultados de la simulación

A continuación se presentan cuatro tablas donde se describen las métricas de evaluación de los modelos para la clasificación de personas alcoholicas y no-alcoholicas, los parametros de los modelos seleccionados, además de las matrices de confusión.

Tabla 1. Métricas - Clasificador SVM no lineal

Metricas - Clasificador SVM - No lineal				
Métricas	Características			
	Máx	Mín	Ran	Std
Exactitud	83.16%	83.91%	92.25%	92.33%
F1 - macro	83.14%	83.89%	92.24%	92.32%
Precisión	81.81%	83.07%	91.35%	92.23%
Sensibilidad	85.50%	85.50%	93.50%	92.83%

Tabla 2. Métricas - Clasificador MLP

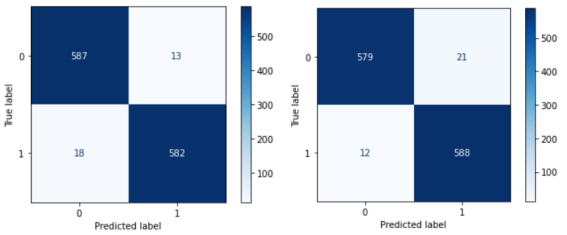
Metricas - Clasificador MLP				
Métricas	Características			
	Máx	Mín	Ran	Std
Exactitud	84.16%	83.25%	92.75%	91.25%
F1 - macro	84.14%	83.24%	92.75%	91.23%
Precisión	84.36%	83.34%	92.37%	91.14%
Sensibilidad	83.83%	85.16%	93.16%	91.83%

Tabla 3. Parametros - Clasificador MLP

Parametros de los clasificadores MLP				
Parametros	Características			
	Máx	Mín	Ran	Std
Hidden - Layers	17	17	18	18
Activation	relu	relu	relu	relu
Solver	lbfgs	adam	lbfgs	lbfgs
Gamma	0.1	0.001	0.1	0.1

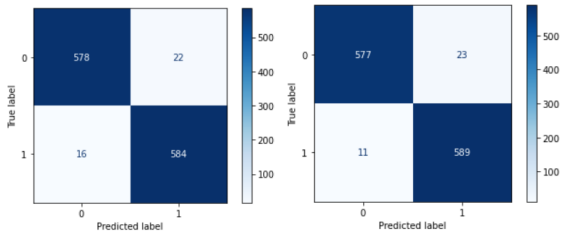
Tabla 4. Parametros - Clasificador SVM

Parametros de los clasificadores SVM				
Parametros	Características			
	Máx	Mín	Ran	Std
Kernel	rbf	rbf	rbf	rbf
C	10	10	10	100
Gamma	auto	auto	auto	auto



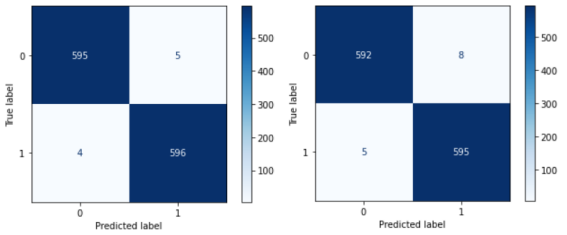
(a) MLP (b) SVM

Fig. 7: Clasificación - Valor Máximo



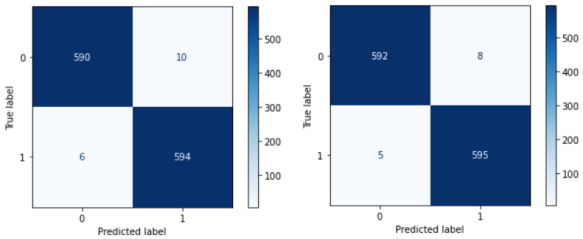
(a) MLP (b) SVM

Fig. 8: Clasificación - Valor Mínimo



(a) MLP (b) SVM

Fig. 9: Clasificación - Rango



(a) MLP (b) SVM

Fig. 10: Clasificación - Desviación Estandar

En las tablas 1 y 2 se presentan las métricas de evaluación obtenidas por los modelos finales, los cuales fueron seleccionados por la herramienta GridSearchCV al suministrarle una amplia variedad de parámetros. Los parámetros que describían a los mejores modelos se encuentran presentados en las tablas 3 y 4 para el MLP y SVM. Finalmente en las figuras 7, 8, 9

y 10 se observa el comportamiento de los modelos al hacer la clasificación binaria (1 iteración) de los sujetos alcohólicos y los no-alcohólicos.

VI. Conclusiones

La clasificación mediante el uso de técnicas de aprendizaje automático a través del análisis de una señal de EEG para identificar si una persona padece o no una predisposición al alcoholismo puede proporcionar un diagnóstico preventivo para que la persona esté consciente de su condición de vulnerabilidad y así poder evitar eventos no deseados (tanto accidentes, como una adicción profunda o enfermedad crónica a causa del alcohol)

La extracción de las características de las señales EEG por medio del análisis estadístico en el dominio del tiempo tiene un alto potencial, principalmente en los valores máximos, mínimos, rango y desviación estándar, ya que se trataban de señales donde una de las clases presenta un aumento considerable de la amplitud en respuesta a los estímulos presentados. Se puede evidenciar que las redes neuronales tuvieron un mejor comportamiento en características como valores mínimos y desviación estándar, 83.91% y 92.33% contra un, 83.25%, 91.25% y en valores F1-macro 83.89% y 92.32% contra un 83.24% y 91.23%

References

1 S. Siuly, Y. L. and Zang, Y., in *EEG Signal Analysis and Classification Techniques and Applications*, pp. 7 – 8.

2 Ritchie, H. and Roser, M., "Alcohol Consumption." 2021.

3 J, W. S. M. K. H., "Alcoholism identification via convolutional neural network based on parametric relu, dropout, and batch normalization," in *Neural Comput & Applic*, vol. 32, 2020, pp. 665–680.

4 Enas Abdulhay, C. M. B. V. N. K., "Automated diagnosis of epilepsy from eeg signals using ensemble learning approach,," vol. 139, 2020, pp. 174–181.

5 Dipali Bansal, R. M., "EEG-Based Brain-Computer Interfaces," vol. 55, 2019, pp. 1–19.

6 Rakesh Ranjan, S. L. F. E. S. V. J., "A fuzzy neural network approach for automatic k-complex detection in sleep eeg signal," in *Pattern Recognition Letters*, 2018, pp. 74–83.

7 Ueda, Y. . Y. H., "Quantitative evaluation of sense of discrepancy to operation response using event-related potential." 2019.

8 Begleiter, H., "Eeg dataset," in *https://archive.ics.uci.edu/ml/datasets/eeg*. the State University of New York Health Center at Brooklyn.

9 A. Gharaviri, M. T. and Abrishami, H., "Comparison of neural network, anfis, and svm classifiers for pvc arrhythmia detection," in *EEE International Conference on Machine Learning and Cybernetics*, 2008.

10 Andreas C. Müller, S. G., "Introduction to machine learning with python," 2016, pp. 266–267.